

แบบจำลองการพยากรณ์อันดับเครดิตของผู้ออกตราสารหนี้

พรพิพัฒน์ ลิ้มคนาวีระ^{1*}, ณิชากานต์ ปานกลาง¹, กฤษฎา โลบุญ¹, พิชญากักร์ หวังปัด¹, รมิตา ดำช่วย¹ และ
นวรรตน์ เต็มสัมฤทธิ์¹

Pornpipat Leelakanaweera^{1*}, Nichakan Panklang¹, Kritsada Loboorn¹, Pitchayapak Whingpad¹,
Ramita Dumchuay¹ and Navarat Temsumrit¹

บทคัดย่อ

งานฉบับนี้จัดทำขึ้นเพื่อศึกษาในเรื่องการสร้างแบบจำลองการพยากรณ์อันดับเครดิตของผู้ออกตราสารหนี้ โดยใช้ข้อมูลทุติยภูมิ ประกอบด้วย ข้อมูลอันดับความน่าเชื่อถือของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยประเภทธุรกิจที่จัดทำโดยบริษัททริสเรตติ้ง จำกัด และข้อมูลทางการเงินของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยตั้งแต่ปี ค.ศ. 2020 - 2023 จากเว็บไซต์ SET Smart รวมทั้งสิ้น 163 ข้อมูล โดยเครื่องมือที่ใช้ในการศึกษาคือ Machine Learning แบบ Supervised Learning โดยผู้ศึกษาเลือกใช้คือ Decision Tree และ Random Forest จากผลการศึกษาพบว่าตัวแปรอิสระทุกตัวมีความสัมพันธ์กับอันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้ ยกเว้น Net Working Capital to Total Asset ที่ไม่มีนัยสำคัญ และส่วนของการประเมินผลของแบบจำลองโดยใช้ Confusion matrix แบบจำลองที่ใช้ Algorithm แบบ Decision Tree ตัวแปรที่มีความสำคัญมากที่สุดต่ออันดับเครดิตเรตติ้งคือ ขนาดของกิจการ (SIZE) และน้อยที่สุดคือ อัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคา และค่าตัดจำหน่ายต่อรายได้ (EBIT Margin) โดยแบบจำลองมีค่า Overall Accuracy อยู่ที่ 72.73% แบบ Random Forest โดยตัวแปรที่มีความสำคัญมากที่สุดต่ออันดับเครดิตเรตติ้งคือ ขนาดของกิจการ (SIZE) และน้อยที่สุดคือ อัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคา และค่าตัดจำหน่ายต่อรายได้ (EBIT Margin) โดยแบบจำลองมีค่า Overall Accuracy อยู่ที่ 93.94%

*Corresponding author; e-mail address: pornpipat61@gmail.com

¹ภาควิชาเศรษฐศาสตร์ คณะเศรษฐศาสตร์ มหาวิทยาลัยเกษตรศาสตร์ กรุงเทพฯ 10900

¹Department of Economics, Faculty of Economic, Kasetsart University, Bangkok 10900

บทนำ

ที่มาและความสำคัญ

ในยุคปัจจุบันไม่ว่าจะเป็นคนรุ่นใหม่ คนวัยทำงาน หรือคนวัยเกษียณ ต่างให้ความสำคัญกับการลงทุนทั้งสิ้น เพราะผลตอบแทนจากการลงทุนทำให้เงินที่มีอยู่งอกเงยได้มากกว่าการนำเงินไปฝากไว้กับธนาคาร การลงทุนสามารถทำได้หลากหลายวิธี ซึ่งหนึ่งในนั้นคือ การลงทุนในตราสารหนี้ ซึ่งตราสารหนี้คือ ตราสารทางการเงินที่ผู้ออกหรือนักลงทุนมีสถานะเป็นเจ้าหนี้ และผู้ออกมีสถานะเป็นลูกหนี้ โดยเจ้าหนี้จะได้รับผลตอบแทนในรูปดอกเบี้ยอย่างสม่ำเสมอตามระยะเวลาที่กำหนด และจะได้รับเงินต้นคืนเมื่อครบกำหนดอายุ เช่น ตัวเงินคลัง พันธบัตรรัฐบาล และหุ้นกู้เอกชน โดยตราสารหนี้เป็นการลงทุนที่มีความเสี่ยงน้อยแต่ให้ผลตอบแทนสม่ำเสมอเฉลี่ยอยู่ที่ 2 - 5% ซึ่งสูงกว่าดอกเบี้ยเงินฝากทั่วไปให้ดอกเบี้ยประมาณ 0.3 - 0.5% (ตลาดหลักทรัพย์แห่งประเทศไทย, 2020)

ในช่วงที่ผ่านมาความนิยมการลงทุนในตราสารหนี้มีแนวโน้มเพิ่มสูงขึ้นตั้งแต่เดือนธันวาคม 2020 ถึงเดือนธันวาคมปี 2023 จำนวนบุคคลธรรมดาที่ถือครองตราสารหนี้เมื่อเทียบกับทุกประเภทแล้ว มีแนวโน้มที่เพิ่มมากขึ้น ซึ่งสาเหตุมาจากการที่อัตราดอกเบี้ยนโยบายอยู่ในช่วงขาขึ้น โดยในช่วงปี 2020 อัตราดอกเบี้ยโดยเฉลี่ยอยู่ที่ 0.61% และปี 2024 อยู่ที่ 2% อัตราผลตอบแทนระยะยาวในปัจจุบันอยู่ในระดับสูง ขณะที่ตราสารหนี้เอกชนหรือ Corporate Bonds ให้ผลตอบแทนที่สูงกว่าพันธบัตรรัฐบาลหรือมี Credit Spreads ที่มากพอที่จะชดเชยความเสี่ยงจากการผิดนัดชำระหนี้หรือความเสี่ยงจากการถูกปรับลดอันดับความน่าเชื่อถือลงได้ (Morningstar, 2024) ดังนั้นเพื่อเป็นการป้องกันความเสี่ยงจากการลงทุนในตราสารหนี้จากการที่เอกชนมีต้นทุนทางการเงินในการออกพันธบัตรเพิ่มขึ้น และอาจนำไปสู่การเกิดการผิดนัดชำระหนี้ที่มากขึ้นตาม ไม่เว้นแม้แต่บริษัทที่จดทะเบียนในตลาดหลักทรัพย์ เช่น กรณี JKN, ALL และ STARK ที่มีการผิดนัดชำระหนี้หุ้นกู้ ซึ่งโดยทั่วไปตราสารหนี้ที่ซื้อขายกันในตลาดทั่วไป มีข้อกำหนดว่าต้องผ่านการประเมิน Credit Rating จากบริษัทจัดอันดับเครดิต (CRA : Credit Rating Agency) ที่ได้รับการรับรองโดยสำนักงานกำกับหลักทรัพย์และตลาดหลักทรัพย์ (ก.ล.ต.) ซึ่งขณะนี้ในประเทศไทยมีอยู่ 2 บริษัท คือ บริษัท ทริสเรตติ้ง จำกัด และ บริษัท ฟิทช์ เรตติ้งส์ (ประเทศไทย) จำกัด โดยจะจัดอันดับเป็นเกรดตั้งแต่สูงสุดคือ AAA ไปจนถึงต่ำสุดคือ D (PeerPower, 2023) ซึ่งในการจัดอันดับเครดิตเรตติ้งของตราสารหนี้ ผู้ที่ออกตราสารต้องเสียค่าใช้จ่ายให้บริษัทจัดอันดับเครดิตเรตติ้ง จึงมีข้อกังวลเกี่ยวกับความโปร่งใสในการจัดอันดับ ที่ผู้จัดเรตติ้งมีโอกาสที่จะให้เรตติ้งที่สูงเพื่อให้ความพึงพอใจกับผู้ออกตราสารหนี้ที่จ่ายเงินให้กับบริษัท และนอกจากนี้ในการจัดอันดับเครดิตเรตติ้งยังใช้ระยะเวลาในการออกประมาณหนึ่ง โดยจะใช้ระยะเวลาประมาณ 6 - 8 สัปดาห์หลังจากมีการเริ่มจัดอันดับแล้ว

จากที่กล่าวมาข้างต้นการศึกษาในครั้งนี้จึงมีวัตถุประสงค์เพื่อสร้างแบบจำลองการพยากรณ์เครดิตเรตติ้งของผู้ออกตราสารหนี้โดยใช้ Machine Learning เนื่องจากในการศึกษาที่ผ่านมายังไม่เคยมีการใช้เครื่องมือนี้มาก่อน โดยสิ่งที่เป็ประโยชน์จากการศึกษาครั้งนี้คือเพื่อเป็นข้อมูลอีกทางเลือกหนึ่งให้กับนักลงทุนทั่วไป ผู้จัดการกองทุน หรือแอปพลิเคชันทางการเงินต่าง ๆ ใช้ในการประกอบการตัดสินใจในการลงทุนในตราสารหนี้หรือแนะนำตราสารหนี้ให้กับลูกค้าของตน

วัตถุประสงค์

เพื่อเป็นข้อมูลทางเลือกในการตัดสินใจให้กับนักลงทุนนอกเหนือจากเครดิตเรตติ้งเอเจนซีในปัจจุบัน

ประโยชน์ที่คาดว่าจะได้รับการศึกษา

นักลงทุนและผู้ที่เกี่ยวข้อง สามารถนำข้อมูลไปใช้ในการวางแผนทางการลงทุนประกอบการตัดสินใจในการเลือกการลงทุนในหลักทรัพย์ได้อย่างถูกต้องและมีประสิทธิภาพ

ขอบเขตการศึกษา

ข้อมูลอันดับความน่าเชื่อถือของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยประเภทธุรกิจที่จัดทำโดยบริษัททริสเรตติ้ง จำกัด และ ข้อมูลทางการเงินของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยตั้งแต่ปี ค.ศ. 2020-2023 จากเว็บไซต์ SET Smart รวมทั้งสิ้น 163 ข้อมูล

ทบทวนวรรณกรรม

งานวิจัยที่เกี่ยวข้องกับแบบจำลองการพยากรณ์อันดับเครดิตของผู้ออกตราสารหนี้ สามารถแบ่งออกได้เป็น 3 ส่วน ส่วนแรกคือ อัตราส่วนทางการเงินที่แสดงความสามารถในการทำกำไร งานวิจัยของธรณ์ธันย์ หวังคณาภ (2017) งานวิจัยของเอนก อรุณศรีแสงไชย และคณะ (2011) และงานวิจัยของ พิชามญชุ์ ธนะอนันต์มงคล (2021) พบว่า อัตราส่วนผลตอบแทนต่อสินทรัพย์รวมมีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต หมายความว่า หากความสามารถในการทำกำไรเทียบกับสินทรัพย์ที่มีก่อให้เกิดผลตอบแทนกลับคืนมามากก็จะทำให้อันดับเครดิตสูงขึ้น ขณะเดียวกันงานวิจัยของฐาณินี ต้นโสรัจประเสริฐ (2021) ได้ให้ผลการศึกษาเกี่ยวกับการควบคุมต้นทุนการผลิตที่ดีจะทำให้อันดับเครดิตสูงขึ้น งานวิจัยของกรรณิกา วิวัฒน์บุตรสิริ (2019) พบว่า อัตราส่วนกำไรสุทธิก่อนดอกเบี้ยและภาษีต่อกับส่วนต่างอัตราดอกเบี้ยมีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต หมายความว่า บริษัทที่มีกำไรก่อนหักดอกเบี้ยและภาษีต่าง ๆ ที่อาจมาจากการกั๊ยืมทำให้

ภาระดอกเบี้ยมากขึ้น แต่หากบริษัทนั้นมีความสามารถในการทำกำไรมาก บริษัทนั้นก็จะมีอันดับเครดิตที่สูง และ ส่วนต่างอัตราดอกเบี้ยเป็นเกณฑ์ที่ประเมินความมีประสิทธิภาพในการทำกำไรมีผลต่อการจัดอันดับเครดิตของบริษัทในกลุ่มสถาบันการเงิน และงานวิจัยของชุดิกายจน์ ชำนาญพุกษา (2004) พบว่าอัตราส่วนกำไรขั้นต้นต่อยอดขาย มีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต กล่าวคือ หากกิจการหรือธุรกิจมีความสามารถในการทำกำไรได้มาก จะทำให้อันดับเครดิตของบริษัทนั้นอยู่ในระดับสูง แต่อัตราส่วนผลตอบแทนต่อส่วนผู้ถือหุ้นมีความสัมพันธ์ในทิศทางตรงกันข้ามกับการจัดอันดับเครดิต หมายความว่า บริษัทที่มีอัตราส่วนผลตอบแทนจากผู้ถือหุ้นเพิ่มขึ้นจะมีคะแนนอันดับเครดิตที่ต่ำ หากอธิบายผ่าน DuPont Analysis ซึ่งประกอบไปด้วย $ROA \times (NET\ Profit\ margin / EBIT\ margin) \times (Asset / Equity)$ อาจเป็นไปได้ว่า ROE ที่สูงเกิดจาก Asset/Equity สูง กล่าวคือกิจการมีหนี้สินที่มาก ซึ่งสอดคล้องกับข้อมูลของบริษัทที่ได้ทำการศึกษาพบว่าบริษัทที่ได้รับการจัดอันดับเครดิตสูงจะมีค่า ROE ที่ต่ำเนื่องจากมีส่วนของผู้ถือหุ้นสูง

ส่วนที่สองคือ อัตราส่วนอื่น ๆ งานวิจัยของเอนก อรุณศรีแสงไชย และคณะ (2011) พบว่า อัตราส่วนเงินทุนหมุนเวียนต่อสินทรัพย์รวม มีความสัมพันธ์ในทิศทางตรงกันข้ามกับการจัดอันดับเครดิต กล่าวคือ บริษัทที่มีเงินทุนหมุนเวียนมากขึ้นหรือก็คือการที่บริษัทมีสภาพคล่องมากขึ้นกลับมีคะแนนเครดิต (AR) และโอกาสที่จะได้รับอันดับเครดิตสูงขึ้นลดลง และยังพบว่า อัตราส่วนหนี้สินต่อส่วนของผู้ถือหุ้น มีความสัมพันธ์ในทิศทางตรงกันข้ามกับการจัดอันดับเครดิต กล่าวคือ หากค่านี้นสูงจะส่งผลให้กิจการมีความเสี่ยงสูงในการที่จะไม่สามารถชำระหนี้ได้สูง และยังทำให้ระดับความน่าเชื่อถือลดลง ขณะเดียวกันงานวิจัยของธรรณัณย์ หวังคนาลาก (2017) ได้ให้ผลการศึกษาเกี่ยวกับอัตราส่วนเงินทุนต่อสินทรัพย์รวมในความหมายที่สอดคล้องกัน ส่วนงานวิจัยของฐาณินี ต้นโสรัจ ประเสริฐ (2021) ได้ให้ผลการศึกษาเกี่ยวกับอัตราส่วนหนี้สินต่อส่วนของผู้ถือหุ้นในทิศทางเดียวกัน และยังพบว่า อัตราส่วนความสามารถในการจ่ายดอกเบี้ยมีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต กล่าวคือ หากธุรกิจมีความสามารถในการจ่ายดอกเบี้ยได้ดีหรือไม่มีปัญหาในการจ่ายชำระคืนก็จะส่งผลให้ระดับความน่าเชื่อถืออยู่ในระดับที่สูง ขณะเดียวกันงานวิจัยของพิชามญช์ ธนะอนันต์มงคล (2021) ได้ให้ผลการศึกษาเกี่ยวกับอัตราส่วนความสามารถในการจ่ายดอกเบี้ยในทิศทางเดียวกัน และงานวิจัยของชุดิกายจน์ ชำนาญพุกษา (2004) พบว่า อัตราส่วนกำไรก่อนดอกเบี้ย ภาษีเงินได้ ค่าเสื่อมราคาและรายการตัดจ่าย ต่อหนี้สินรวม มีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต หมายความว่า บริษัทที่มีกำไรก่อนหักดอกเบี้ยและภาษีต่าง ๆ รวมถึงต้นทุนทางธุรกิจ หากบริษัทนั้นมีความสามารถในการทำกำไรมากและมีสัดส่วนมากกว่าหนี้สิน บริษัทนั้นก็จะมีอันดับเครดิตที่สูงขึ้นเช่นกัน

และส่วนสุดท้าย ตัวแปรที่ไม่ใช่อัตราส่วนทางการเงิน งานวิจัยของธรรณัณย์ หวังคนาลาก (2017) งานวิจัยของกรรณิกา วิวัฒน์บุตริ (2019) และงานวิจัยของเอนก อรุณศรีแสงไชยและคณะ (2011) พบว่า ขนาดของกิจการมีความสัมพันธ์ในทิศทางเดียวกันกับการจัดอันดับเครดิต ซึ่งหมายความว่า กิจการขนาดใหญ่ที่มีสินทรัพย์มาก ความมั่นคงของกิจการก็จะสูงขึ้น ทำให้มีอันดับเครดิตที่สูงขึ้น นอกจากนี้งานวิจัยของฐาณินี ต้นโสรัจ

ประเสริฐ (2021) และงานวิจัยของพิชามญชุ์ ธนะอนันต์มิ่งคล (2021) ได้ให้ผลการศึกษาเกี่ยวกับขนาดของกิจการ ในความหมายเดียวกัน และยังพบว่า อันดับความน่าเชื่อถือระดับประเทศมีความสัมพันธ์ในทิศทางเดียวกันกับการ จัดอันดับเครดิต หมายความว่า กิจการที่มีการจัดอันดับความน่าเชื่อถือระดับประเทศในระดับสูงหรืออยู่ในเกณฑ์ที่ ดี ความมั่นคงของกิจการนั้นก็จะมีเพิ่มมากขึ้น ส่งผลให้อันดับเครดิตที่สูงขึ้น งานวิจัยของกรรณิกา วิวัฒน์บุตรสิริ (2019) พบว่า สถานภาพของบริษัทมีความสัมพันธ์ในทิศทางตรงกันข้ามกับการจัดอันดับเครดิต กล่าวคือ สถานภาพของบริษัท ส่งผลถึงความมั่นคงของบริษัท ทั้งนี้อาจเนื่องมาจากบริษัทที่ใช้เป็นข้อมูลในการศึกษาในครั้งนี้ มีการจัดอันดับเครดิตที่ดี (AAA, AA+, AA, AA-) เป็นบริษัทที่ไม่ได้จดทะเบียนในตลาดหลักทรัพย์จึงเป็นผลทำให้ สถานภาพของบริษัทที่มีค่ามากอันดับเครดิตมีโอกาสปรับตัวลดลง และนอกจากนี้ งานวิจัยของพิชามญชุ์ ธนะอนันต์มิ่งคล (2021) พบว่า การดำเนินงานธุรกิจอย่างยั่งยืนในมิติของ สิ่งแวดล้อม สังคม และธรรมาภิบาล (ESG) มีความสัมพันธ์ในทิศทางตรงกันข้ามกับการจัดอันดับเครดิต กล่าวคือ การประเมินอันดับความน่าเชื่อถือ ได้รับน้ำหนักของคะแนนมาจากการบริหารจัดการทางการเงินมากกว่าค่าน้ำหนักจาก ESG Score จึงทำให้บริษัทที่ ได้รับคะแนน ESG Score ต่ำได้รับคะแนนอันดับความน่าเชื่อถือสูง เพราะมีการบริหารจัดการทางการเงินที่ดี

เครื่องมือที่ใช้ในงานวิจัยที่ผ่านมา

เครื่องมือที่ใช้ในงานวิจัยที่ผ่านมา มีการใช้เครื่องมือในการทดสอบแบบจำลองเพื่อวิเคราะห์ผล 4 แบบ

1. Linear Regression โดยงานวิจัยของธรรณัญญ์ หวังคนาลาก (2017) ได้ใช้หาระดับความสัมพันธ์ของ ตัวแปรอิสระที่เป็นอัตราส่วนทางการเงินกับตัวแปรตาม เพื่อคัดเลือกอัตราส่วนทางการเงินที่เหมาะสมจาก 4 ด้าน ๆ ละ 1 อัตราส่วน และความสัมพันธ์ของตัวแปรอิสระที่เป็นปัจจัยอื่น ๆ โดยคำนวณค่าทางสถิติของ ความสัมพันธ์ต่าง ๆ

2. Ordered Probit Regression โดยงานวิจัยของเอนก อรุณศรีแสงไชย และคณะ (2011) ได้ใช้ Ordered Probit Regression ในการวิเคราะห์อันดับเครดิตของบริษัท ส่วนงานวิจัยของฐาณินี ต้นไธสงประเสริฐ (2021) ใช้ในการวิเคราะห์ความสามารถของกิจการในการปฏิบัติตามภาระทางการเงิน ประเมินค่าด้วยวิธี Maximum likelihood และงานวิจัยของพิชามญชุ์ ธนะอนันต์มิ่งคล (2021) ได้ใช้ในการวิเคราะห์ปัจจัยที่มีผลต่อ อันดับความน่าเชื่อถือ และวิเคราะห์หาระดับความสัมพันธ์ระหว่างสถาบันจัดอันดับความน่าเชื่อถือหรือความเป็น อิสระต่อกันในการให้คะแนนของแต่ละสถาบันจัดอันดับ

3. Random Effect Ordered Probit โดยงานวิจัยของเอนก อรุณศรีแสงไชย และคณะ (2011) ใช้ในการ วิเคราะห์อันดับเครดิตของบริษัทที่แต่ละบริษัทมีลักษณะเฉพาะ

4. Binary Logistic Regression โดยงานวิจัยของชุดิภาญจน์ ชำนาญพุกษา (2004) ใช้ในการวิเคราะห์ จำแนกประเภท โดยจะแบ่งกลุ่มตัวอย่าง 2 ประเภท ได้แก่ ประเภทอันดับเครดิตระดับต่ำ และอันดับเครดิต ระดับสูง

แนวคิดและทฤษฎีที่เกี่ยวข้อง

การศึกษาในครั้งนี้ คณะผู้จัดทำได้ทำการศึกษาในเรื่อง “แบบจำลองการพยากรณ์อันดับเครดิตของผู้ออกตราสารหนี้” โดยได้ทำการศึกษาแนวคิดและทฤษฎีที่เกี่ยวข้องเพื่อนำมาใช้เป็นแนวทางในการศึกษา ดังนี้

1. อันดับความน่าเชื่อถือ (Credit Rating)

อันดับความน่าเชื่อถือ (Credit Rating) คือ การประเมินความน่าเชื่อถือของผู้ออกตราสารหนี้หรือหุ้นกู้ โดยสถาบันจัดอันดับความน่าเชื่อถือ ที่ได้รับการรับรองจากสำนักงานกำกับหลักทรัพย์และตลาดหลักทรัพย์ โดยประเทศไทยมีอยู่สองแห่ง ได้แก่ TRIS Rating และ Fitch Rating Thailand โดยบริษัทจัดอันดับเครดิตจะวิเคราะห์จากผลการดำเนินงานและความเสี่ยงต่าง ๆ ที่มีผลกระทบต่อบริษัท ซึ่งนักลงทุนจะต้องติดตามการเปลี่ยนแปลงอันดับเครดิตตลอดระยะเวลาการลงทุน

โดยตราสารหนี้ที่อันดับเครดิตสูง ความเสี่ยงในการผิดนัดชำระหนี้ก็ยิ่งต่ำ ซึ่งอันดับความน่าเชื่อถือจะถูกแบ่งเป็นสองกลุ่ม คือ Investment Grade หรือ กลุ่มน่าลงทุน แบ่งเป็นเกรด AAA ถึง BBB- และ Speculative Grade (Non-investment Grade) หรือกลุ่มเก็งกำไร แบ่งเป็นเกรด BB+ ลงไปจนถึง D (ThaiBMA, 2017) ดังตารางที่ 1

ตารางที่ 1 ตารางแสดงระดับ Credit Rating ของตราสารหนี้

Investment Grade	Grade	Speculative Grade (Non-investment Grade)	Grade
	AAA		BB+
	AA+		BB
	AA		BB-
	AA-		B+
	A+		B
	A		B-
	A-		CCC+
	BBB+		CCC
	BBB		CCC-
	BBB-		CC
			C
			D

2. Machine Learning

Machine Learning คือ การทำให้คอมพิวเตอร์ สามารถเรียนรู้สิ่งต่าง ๆ และพัฒนาการทำงานให้ดีขึ้นได้ด้วยตนเองจากข้อมูลและสภาพแวดล้อมที่ได้รับจากการเรียนรู้ของระบบ โดยไม่ต้องมีมนุษย์คอยกำกับหรือเขียนโปรแกรมเพิ่มเติม เพราะคอมพิวเตอร์สามารถตีความและตอบสนองได้ด้วยตนเอง

Machine Learning เป็นการทำงานในลักษณะการป้อนชุดข้อมูลพื้นฐานและชุดคำสั่งต่าง ๆ เพื่อให้คอมพิวเตอร์ “เรียนรู้” และจำแนกแยกแยะวัตถุต่าง ๆ รวมถึงบุคคล สิ่งของ เป็นต้น และเพื่อให้ได้ผลลัพธ์ที่แม่นยำมากขึ้น โปรแกรมเมอร์จึงมีการป้อนชุดข้อมูลใหม่ ๆ และต้องฝึกฝนระบบอย่างสม่ำเสมอ เพื่อให้เกิดวิวัฒนาการของระบบ ทำให้ระบบคิดได้ด้วยตนเองในเวลาต่อมา

โดยหลักการของ Machine Learning จะแบ่งออกเป็น 3 ประเภทตามรูปแบบการเรียนรู้ ได้แก่

- Supervised Learning หรือการเรียนรู้แบบมีผู้สอน

เป็นการทำให้คอมพิวเตอร์สามารถหาคำตอบของปัญหาได้ด้วยตัวเอง หลังจากเรียนรู้จากชุดข้อมูลตัวอย่างไปแล้วระยะหนึ่ง ยกตัวอย่างเวลาเราป้อนข้อมูลให้กับคอมพิวเตอร์ (Input) เช่น รูปปากกา เบื้องต้นคอมพิวเตอร์จะยังไม่รู้ว่ารูปที่เราป้อนเข้าไป คือรูปปากกา เราจึงต้องสอนให้คอมพิวเตอร์รู้จักเพื่อนำไปวิเคราะห์ (Feature Extraction) ว่าปากกาจะมีปลายด้ามเป็นปุ่ม และใช้หมึกในการเขียน เป็นต้น จากนั้นคอมพิวเตอร์ก็นำข้อมูลดังกล่าวไปประมวล/จัดหมวดหมู่ (Classification) เพื่อให้หลังจากนั้นมันสามารถแยกออกได้ว่าอะไรคือปากกา อะไรไม่ใช่ปากกา

- Unsupervised Learning หรือ การเรียนรู้โดยไม่มีผู้สอน

เป็นการเรียนรู้ที่คอมพิวเตอร์สามารถเรียนรู้ได้ด้วยตนเอง โดยไม่ต้องมีค่าเป้าหมายของแต่ละข้อมูล ซึ่งวิธีการคือมนุษย์จะเป็นผู้ใส่ข้อมูลต่าง ๆ และกำหนดสิ่งที่ต้องการจากข้อมูลเหล่านั้น ทำให้คอมพิวเตอร์วิเคราะห์จากการจำแนกและสร้างแบบแผนจากข้อมูลที่ได้รับมา ซึ่งตรงข้ามกับรูปแบบ Supervised Learning ตัวอย่างเช่น การที่เราป้อนข้อมูล (Input) รูปปากกาเข้าไป แต่ไม่ได้บอกว่ารูปที่ป้อนเข้าไปเป็นรูปปากกา เมื่อคอมพิวเตอร์นำไปวิเคราะห์ (Feature Extraction) ก็ยังสามารถวิเคราะห์ได้ว่ารูปที่ใส่เข้าไปมีลักษณะยังไง แต่ยังไม่สามารถเอาไปประมวล/จัดหมวดหมู่ (Classification) ได้ จึงใช้วิธีการแบ่งกลุ่มแทน (Clustering) ซึ่งคอมพิวเตอร์อาจเอารูปปากกาไปจัดกลุ่มกับปากกาไฮไลต์ หรือเครื่องเขียนอื่น ๆ ที่มีปลายด้ามเป็นปุ่ม และใช้หมึกในการเขียนเหมือนกัน เป็นต้น

- Reinforcement Learning หรือ การเรียนรู้แบบเสริมกำลัง

เป็นวิธีการเรียนรู้แบบหนึ่งที่เกิดมาจากการปฏิสัมพันธ์ (interaction) ระหว่างผู้เรียนรู้ (agent) กับสิ่งแวดล้อม (environment) ที่มีการเรียนรู้สิ่งต่าง ๆ จาก Agent ภายใต้การเลือกกระทำสิ่งต่าง ๆ ให้ได้ผลลัพธ์ที่มากที่สุด ผ่านการลองผิดลองถูกภายใต้สถานการณ์หรือระบบจำลอง ที่พัฒนาระบบการตัดสินใจให้ดีขึ้นเรื่อย ๆ หรือคือการที่กำหนดเงื่อนไขบางอย่างให้กับคอมพิวเตอร์ แล้วทำให้คอมพิวเตอร์บรรลุหรือทำตามเงื่อนไขนั้นให้ได้ ผ่านการลองผิดลองถูก โดยผู้พัฒนาอาจตั้งเป้าหมาย Feedback Loop และเงื่อนไขในการได้รับรางวัล ยกตัวอย่างเช่น Alpha Go เงื่อนไขของการเล่นเกมหมากล้อมให้ชนะคือ ใช้น้ำหมากของตนล้อมพื้นที่บนกระดานให้ครอบคลุมดินแดนมากกว่าคู่ต่อสู้ หลังจาก Alpha Go เรียนรู้ว่าจะหากคู่ต่อสู้เดินหมากนี้ ตัวมันจะเดินหมากไหนเพื่อให้บรรลุเงื่อนไขที่กำหนดไว้ให้ นั่นคือการยึดพื้นที่บนกระดานให้ได้มากที่สุด (cyber elite, 2022)

3. Confusion Matrix

Confusion matrix คือ เครื่องมือสำคัญในการประเมินประสิทธิภาพของ Classification machine learning รูปแบบต่าง ๆ ร่วมกับชุดข้อมูลทดสอบที่ทราบค่าหรือผลลัพธ์ที่แท้จริง จากนั้นทำการประเมินค่าจริง (Actual value) เทียบกับค่าที่ได้จากผลลัพธ์ของโมเดลหรือค่าที่คาดการณ์ไว้ (Predicted Value) แล้วสรุปค่าออกมาในรูปแบบของตารางเมทริกซ์ที่ประกอบด้วย (ตารางที่ 2)

ตารางที่ 2 ตารางแสดงรูปแบบของ Confusion Matrix

Confusion Matrix		
	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

- True Positives (TP)

คือ จำนวนข้อมูลที่ถูกจำแนกได้อย่างถูกต้องในกลุ่มของประเภทที่ต้องการ (Positive class) หรือกลุ่มที่สนใจ ในกรณีนี้คือข้อมูลที่ถูกทำนายว่าเป็น Positive หรือเป็นแบบนี้จริง และข้อมูลจริงก็เป็นแบบนี้จริง ๆ หรือก็คือการทำนายถูกต้องว่าสิ่งที่ประเมินไว้จะเกิดขึ้น

- True Negatives (TN)

คือ จำนวนข้อมูลที่ถูกจำแนกถูกต้องในกลุ่มของประเภทที่ไม่ใช่เป้าหมาย (Negative class) หรือกลุ่มที่ไม่สนใจ ในกรณีนี้คือข้อมูลที่ถูกทำนายว่าเป็น Negative และข้อมูลจริงเป็น Negative นั่นคือการทำนายถูกต้องว่าไม่เป็นสิ่งที่ประเมินไว้

- False Positives (FP)

คือ จำนวนข้อมูลที่ถูกทำนายผิดในกลุ่มของประเภทที่สนใจ ในกรณีนี้คือข้อมูลที่ถูกทำนายว่าเป็น Positive แต่ข้อมูลจริงกลับเป็น Negative นั่นคือการทำนายผิดว่าเป็นสิ่งที่ทำการประเมินไว้ หรือ False

- False Negatives (FN)

คือ จำนวนข้อมูลที่ถูกจำแนกผิดในกลุ่มของประเภทที่ไม่สนใจ ในกรณีนี้คือข้อมูลที่ถูกทำนายว่าเป็น Negative แต่ข้อมูลจริงกลับเป็น Positive นั่นคือการทำนายผิดว่าไม่เป็นสิ่งที่ประเมินไว้

จากนั้นผ่านการคำนวณค่าพารามิเตอร์ที่ใช้ประเมิน 4 ค่าได้แก่

- ความแม่นยำ (Accuracy)

คือ ค่าความแม่นยำเป็นสัดส่วนของข้อมูลทั้งหมดที่ถูกจำแนกถูกต้องโดยระบบ ซึ่งคำนวณได้จาก “จำนวน (True Positives (TP) + True Negatives (TN)) / จำนวนทั้งหมด” ซึ่งค่า Accuracy จะใช้บอกถึงความสามารถของโมเดลโดยรวมในการ Predict ทั้งในกรณี Positive และ Negative

- ความแม่นยำในการทำนายในกลุ่มเป้าหมาย (Precision)

คือ ค่าความแม่นยำในการทำนายในกลุ่มเป้าหมายหรือพิจารณาเฉพาะที่เป็น True Positives (TP) โดยสามารถคำนวณได้จาก “จำนวน True Positives (TP) / จำนวน (True Positives (TP) + False Positives (FP))” ซึ่งค่า Precision จะใช้พิจารณาถึงความสามารถของระบบในการทำนาย Positive โดยเฉพาะ

- ความสามารถในการตรวจจับเหตุการณ์ที่สนใจ (Recall)

คือ ความสามารถของ Model ในการ Predict หรือระบุสิ่งที่สนใจ ซึ่งคือสัดส่วนของ True Positives (TP) กับข้อมูลที่จริง ๆ เป็น Positive ทั้งหมด โดยสามารถคำนวณได้จาก “จำนวน True Positives (TP) / จำนวน (True Positives (TP) + False Negatives (FN))” โดยที่ Recall จะใช้ประเมินความประสิทธิภาพในการ Predict ของโมเดลในการประเมินผล Positive ในกรณีที่มี Positive จริง

- **ค่า F1-Score**

คือ ค่าความสมดุลระหว่างความแม่นยำในการทำนายในกลุ่มเป้าหมาย (Precision) และความสามารถในการตรวจจับเหตุการณ์ที่สนใจ (Recall) โดยสามารถคำนวณได้จาก $2 * (Precision * Recall) / (Precision + Recall)$ โดยที่ค่า F1-Score มีค่าสูงเมื่อทั้งความแม่นยำในการ Predict กลุ่มเป้าหมาย และความสามารถในการประเมิน Positive มีค่าสูงพร้อมกัน ซึ่งเป็นสิ่งที่แสดงถึงประสิทธิภาพโดยรวมของ ML Model (Everyday Marketing, 2023)

วิธีการศึกษา

การศึกษาเรื่อง “แบบจำลองการพยากรณ์อันดับเครดิตของผู้ออกตราสารหนี้” ในครั้งนี้ ได้แบ่งวิธีการศึกษาออกเป็น การเก็บรวบรวมข้อมูลและข้อมูลที่ใช้ในการศึกษา เครื่องมือที่ใช้ในการศึกษา ตัวแปรที่ใช้ในการศึกษา และขั้นตอนในการสร้างแบบจำลอง

1. การเก็บรวบรวมข้อมูลและข้อมูลที่ใช้ในการศึกษา

การศึกษานี้ทำการเก็บรวบรวมข้อมูลในรูปแบบทุติยภูมิ ประกอบด้วย ข้อมูลอันดับความน่าเชื่อถือของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยประเภทธุรกิจที่จัดทำโดยบริษัททริสเรตติ้ง จำกัด (trisrating, 2024) และข้อมูลทางการเงินของบริษัทที่จดทะเบียนในตลาดหลักทรัพย์แห่งประเทศไทยจากเว็บไซต์ SET Smart (SET Smart, 2024) ตั้งแต่ปี ค.ศ. 2020-2023 รวมระยะเวลา 4 ปี จำนวน 43 บริษัท เป็นข้อมูลพาแนล (Panel Data) รวมทั้งสิ้น 163 ข้อมูล โดยจะเน้นการเก็บรวบรวมข้อมูลของบริษัทที่อยู่ในภาคธุรกิจเท่านั้น เนื่องจากบริษัทที่อยู่ในภาคธุรกิจสามารถหาข้อมูลเกี่ยวกับปัจจัยพื้นฐานได้ง่ายเพราะโดยส่วนมากนั้นมีข้อมูลอยู่ในฐานข้อมูลของตลาดหลักทรัพย์ นอกจากนี้ยังศึกษาอันดับเครดิตเรตติ้งทั้งในกลุ่ม Investment Grade และ Non-investment Grade (Speculative Grade)

โดยจากข้อมูลทั้งหมด 163 ข้อมูล ได้มีการแบ่งกลุ่มอันดับเครดิตเรตติ้งตามเว็บไซต์ ThaiBMA (2019) ทำให้สามารถแบ่งอันดับเครดิตเรตติ้งได้เป็นอันดับเครดิตเรตติ้งในกลุ่ม Investment Grade จำนวน 135 ข้อมูล ประกอบด้วย อันดับเครดิต AAA จำนวน 5 ข้อมูล อันดับเครดิต AA+ จำนวน 2 ข้อมูล อันดับเครดิต AA จำนวน 6 ข้อมูล อันดับเครดิต AA- จำนวน 8 ข้อมูล อันดับเครดิต A+ จำนวน 17 ข้อมูล อันดับเครดิต A จำนวน 20 ข้อมูล อันดับเครดิต A- จำนวน 16 ข้อมูล อันดับเครดิต BBB+ จำนวน 13 ข้อมูล อันดับเครดิต BBB จำนวน 22 ข้อมูล และอันดับเครดิต BBB- จำนวน 26 ข้อมูล

ถัดมาอันดับเครดิตเรตติ้งในกลุ่ม Speculative Grade (Non-investment Grade) จำนวน 28 ข้อมูล ประกอบด้วย อันดับเครดิต BB+ จำนวน 14 ข้อมูล และอันดับเครดิต BB จำนวน 14 ข้อมูล (แสดงในตารางที่ 3)

ตารางที่ 3 ตารางแสดงจำนวนข้อมูลแต่ละอันดับเครดิต

Investment Grade	no.	Non-investment Grade	no.
AAA	5	BB+	14
AA+	2	BB	14
AA	6		
AA-	8		
A+	17		
A	20		
A-	16		
BBB+	13		
BBB	22		
BBB-	26		

2. เครื่องมือที่ใช้ในการศึกษา

ในส่วน of เครื่องมือที่ใช้ในการศึกษา ผู้ศึกษาได้มีการนำเครื่องมือ Machine Learning ในรูปแบบ Supervised Learning หรือการเรียนรู้แบบมีผู้สอน กล่าวคือ การทำให้คอมพิวเตอร์สามารถหาคำตอบของปัญหาได้ด้วยตนเอง หลังจากเรียนรู้จากชุดข้อมูลตัวอย่างไปแล้วระยะหนึ่ง โดยวิธีการคือ ขั้นแรกจะนำข้อมูลทั้ง Input และ Output ใส่เข้าไปในคอมพิวเตอร์ เพื่อให้คอมพิวเตอร์เกิดการเรียนรู้ เมื่อคอมพิวเตอร์เรียนรู้แล้ว คอมพิวเตอร์จะสร้างสิ่งที่เรียกว่า Model (Logic) ขึ้นมา หลังจากนั้นเมื่อมี Model (Logic) แล้ว แม้จะนำเพียงข้อมูล Input ใส่เข้าไป Model (Logic) ก็จะสามารถพยากรณ์ค่า Output ออกมาได้ ซึ่ง Model (Logic) จะมีความแม่นยำมากน้อยเท่าใดนั้นขึ้นอยู่กับจำนวนและความหลากหลายของ Input และ Output ที่ใส่เข้าไปให้คอมพิวเตอร์เรียนรู้ในขั้นตอนแรก

โดย Machine Learning แบบ Supervised Learning ที่เลือกใช้ได้แก่ Decision Tree และ Random Forest เริ่มที่หลักการของ Decision Tree คือ แบบจำลองรูปแบบการตัดสินใจรูปต้นไม้ที่มีการแตกกิ่งออกไปเรื่อย ๆ จนกลายเป็นหลาย ๆ ใบ ในแต่ละใบมีเงื่อนไขในการตัดสินใจโดยจะเริ่มจากบนสุดไปยังปลายกิ่ง ยิ่งต้นไม้มีความลึกมาก ความแม่นยำในการทำนายจะยิ่งมากขึ้น ในขณะที่หลักการของ Random Forest คือ การสร้างโมเดลจาก Decision Tree หลาย ๆ โมเดลย่อย โดยแต่ละโมเดลของ Decision Tree จะได้รับ Data Set ที่แตกต่างกัน ซึ่ง Decision Tree แต่ละโมเดลใน Random Forest นั้นยังถือว่าเป็น Weak Learner หลังจากนั้นจะนำ Decision Tree แต่ละโมเดลทำ Prediction แยกกัน และทำการคำนวณผล Prediction ด้วยการ Vote

Output ที่ถูกเลือกโดย Decision Tree มากที่สุด (ในกรณี Classification) จะได้โมเดลรวมที่มีความเก่งและความแม่นยำหรือเรียกว่า Random Forest

นอกจากนี้ยังได้มีการใช้สถิติ Spearman Rank Correlation Test หรือการหาความสัมพันธ์ระหว่างตัวแปร 2 ตัวที่อยู่ในมาตราการวัดระดับ Ordinal Scale โดยค่า Spearman Rank Correlation จะมีค่าอยู่ระหว่าง -1.0 ถึง +1.0 หากค่า Spearman Rank Correlation ใกล้ -1.0 นั้นหมายความว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์กันอย่างมากในทางตรงกันข้าม ในขณะที่หากค่า Spearman Rank Correlation ใกล้ +1.0 นั้นหมายความว่า ตัวแปรทั้งสองมีความสัมพันธ์กันอย่างมากในทิศทางเดียวกัน และหากค่า Spearman Rank Correlation มีค่าเท่ากับ 0 นั้นหมายความว่า ตัวแปรทั้งสองตัวไม่มีความสัมพันธ์ต่อกัน (Big Data Institute, 2021) ซึ่งทำเพื่อทดสอบความสัมพันธ์ของตัวแปรต้นต่ออันดับเครดิตเรตติ้ง

3. ตัวแปรที่ใช้ในการศึกษา

3.1 ตัวแปรอิสระ

ในการคัดเลือกตัวแปรต้นเพื่อสร้างแบบจำลอง จะพิจารณาเลือกตัวแปรอิสระที่มีนัยสำคัญต่ออันดับเครดิตเรตติ้งจากงานวิจัยที่ผ่านมา หรือเลือกตัวแปรอิสระจากเกณฑ์การจัดอันดับเครดิตเรตติ้งของ TRIS Rating จากนั้นจึงทำการทดสอบว่าตัวแปรที่คัดเลือกมามีความสัมพันธ์กับอันดับเครดิตเรตติ้งจริงหรือไม่ด้วย Spearman Rank Correlation Test ซึ่งจากการพิจารณาที่กล่าวมา จึงมีตัวแปรอิสระที่คัดเลือกมาทั้งหมด 8 ตัว ได้แก่

- ผลตอบแทนต่อสินทรัพย์ (ROA)

เป็นอัตราส่วนที่บ่งบอกถึงความสามารถในการทำกำไรจากสินทรัพย์ของบริษัท โดยสามารถคำนวณได้จาก $\text{Net Income} / \text{Total Assets}$ โดยสินทรัพย์สุทธิ (Total Assets) ของบริษัทนั้น ประกอบด้วยส่วนของผู้ถือหุ้นและส่วนของหนี้สิน ค่า ROA ยิ่งสูงยิ่งดี เพราะแสดงว่าบริษัทมีความสามารถในการทำกำไรสูงเมื่อเทียบกับมูลค่าสินทรัพย์ที่ลงทุน หากค่า ROA ของบริษัทต่ำกว่าร้อยละ 5 นักลงทุนมืออาชีพมักจะไม่ให้ความสนใจกับบริษัทนั้น (Set invest now, 2020)

- ผลตอบแทนต่อส่วนของผู้ถือหุ้น (ROE)

เป็นอัตราส่วนที่บ่งบอกถึงความสามารถของบริษัทในการนำเงินลงทุนของผู้ถือหุ้นไปทำให้งอกเงย โดยสามารถคำนวณได้จาก $\text{Net Income} / \text{Equity}$ ค่า ROE ยิ่งสูงยิ่งดี โดยนักลงทุนมืออาชีพจะมองหาหุ้นที่มีค่า ROE สูงกว่าร้อยละ 12 - 15 อย่างต่อเนื่องหลาย ๆ ปี หากนำค่า ROA และ ROE มาพิจารณาแล้ว จะพบว่าอัตราส่วนทั้งสองมีความคล้ายคลึงกัน คือ เป็นตัวบ่งบอกความสามารถในการทำกำไรของบริษัท จุดแตกต่างกันที่สำคัญของอัตราส่วนทั้งสองจะอยู่ที่ "หนี้สิน" ของบริษัท เนื่องจาก $\text{Assets} = \text{Equity} + \text{Liabilities}$ ดังนั้น จากสูตรการหาค่า ROA

และ ROE จะเห็นว่าถ้าบริษัทไม่มีหนี้สิน Liabilities มีค่าเท่ากับ 0 เราจะคำนวณค่า ROA ได้เท่ากับ ROE แต่หากบริษัทมีหนี้สินเยอะ อาจทำให้ค่า ROA ที่ได้มีค่าต่ำ ในขณะที่ ROE มีค่าเท่าเดิม ดังนั้น จึงเป็นสิ่งที่ควรระวังหากพิจารณาเฉพาะค่า ROE ที่สูง ๆ โดยไม่พิจารณาถึงหนี้สินของบริษัท (Set invest now, 2020)

- อัตราส่วนหนี้สินต่อส่วนผู้ถือหุ้น (D/E ratio)

อัตราส่วนที่บอกว่า บริษัทมีหนี้สินเป็นกี่เท่าของส่วนของผู้ถือหุ้น ซึ่งสะท้อนถึงฐานะทางการเงินของบริษัท โดยสามารถคำนวณได้จาก $DE\ Ratio = Debt/Equity$ โดยที่ D คือ Debt หรือหนี้สินรวมของบริษัท และ E คือ Equity หรือส่วนของผู้ถือหุ้นรวม (ลงทุนแมน, 2022)

- อัตราส่วนความสามารถในการจ่ายดอกเบี้ย (ICR)

เป็นอัตราส่วนทางการเงินที่วัดระหว่างกำไรก่อนดอกเบี้ยและภาษีกับดอกเบี้ยจ่าย ซึ่งเป็นอัตราส่วนที่บ่งบอกถึงความสามารถในการชำระดอกเบี้ยเงินกู้ของกิจการ โดยสามารถคำนวณได้จาก $อัตราส่วนความสามารถในการจ่ายดอกเบี้ย = \frac{\text{กำไรก่อนดอกเบี้ยและภาษี}}{\text{ดอกเบี้ยจ่าย}}$ (เท่า) หากค่าที่คำนวณได้ > 1 หมายถึง กิจการสามารถทำรายได้เพียงพอต่อการจ่ายดอกเบี้ย เป็นอัตราที่มีค่ายิ่งสูงยิ่งดี แต่หากค่าที่คำนวณได้ < 1 หมายถึง กิจการไม่สามารถทำรายได้เพียงพอต่อการจ่ายดอกเบี้ยมีความเสี่ยงที่เจ้าหนี้จะบังคับคดีตามกฎหมาย (myaccount cloud accounting, 2019)

- ขนาดกิจการ (SIZE)

ขนาดกิจการวัดโดยขนาดสินทรัพย์รวมของกิจการ (Total Assets)

(มยุรี สินธุเจริญ, 2017)

- Net Working Capital to Total Assets (NWCTA)

เป็นอัตราส่วนทางการเงินที่บ่งชี้ถึงสภาพคล่องในระยะสั้นและความแข็งแกร่งทางการเงินของธุรกิจ และความสามารถในการจัดหาเงินทุนสำหรับภาระผูกพันระยะสั้น โดยคำนวณจาก $NWCTA = \frac{\text{รวมสินทรัพย์หมุนเวียน} - \text{รวมหนี้สินหมุนเวียน}}{\text{ขนาดสินทรัพย์รวมของกิจการ}}$ (Plan Projections, 2022)

- อัตราส่วนกำไรก่อนดอกเบี้ยจ่ายและภาษีต่อรายได้ (EBIT Margin)

เป็นอัตราส่วนที่บ่งบอกถึงความสามารถในการทำกำไรก่อนหักดอกเบี้ยจ่ายและภาษี โดยสามารถคำนวณได้จาก $EBIT\ Margin = \frac{\text{กำไรก่อนดอกเบี้ยจ่ายและภาษี (EBIT)}}{\text{รายได้}} \times 100$ (Set invest now, 2020)

- อัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคา และค่าตัดจำหน่ายต่อรายได้ (EBITDA Margin)

เป็นอัตราส่วนที่บ่งบอกถึงความสามารถในการทำกำไรก่อนหักดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคา และค่าตัดจำหน่าย ซึ่งอัตราส่วน EBITDA Margin ถือว่ามีความสำคัญมากในการวิเคราะห์ ยามที่บริษัทเจอวิกฤติ โดยสามารถคำนวณได้จาก $EBITDA\ Margin = \frac{\text{กำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคาและค่าตัดจำหน่าย}}{\text{รายได้}} \times 100$ หรือ $EBITDA\ Margin = \frac{(EBIT + \text{ค่าเสื่อมราคาและค่าตัดจำหน่าย})}{\text{รายได้}} \times 100$ (Set invest now, 2020)

3.2 ตัวแปรตาม

ในส่วนของตัวแปรตามได้ทำการแบ่งเป็นลำดับเครดิตองค์กรแบบ Investment Grade และลำดับเครดิต องค์กรแบบ Speculative Grade

โดยลำดับเครดิตองค์กรแบบ Investment Grade จะแบ่งเป็น

- High Investment Grade ได้แก่ เกรด AAA, AA+, AA, AA-
- Medium Investment Grade ได้แก่ เกรด A+, A, A-
- Low Investment Grade ได้แก่ เกรด BBB+, BBB, BBB-

ในขณะที่ลำดับเครดิตองค์กรแบบ Speculative Grade ได้แก่ เกรด BB+, BB

4. ขั้นตอนในการสร้างแบบจำลอง

ในกระบวนการสร้างแบบจำลองการพยากรณ์อันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้เริ่มต้นจากการเก็บ รวบรวมข้อมูลที่ใช้ในการเทรนโมเดล โดยสามารถเก็บข้อมูลมาได้ทั้งหมด 163 หน่วยสังเกต และถัดมาคือการแบ่ง ข้อมูลทั้งหมดเป็นสองส่วน ได้แก่ ส่วนสำหรับการเทรนโมเดลเป็นจำนวนร้อยละ 80 ของจำนวนข้อมูลทั้งหมด (130 หน่วยสังเกต) และข้อมูลสำหรับการทดสอบการพยากรณ์ของโมเดลร้อยละ 20 (33 หน่วยสังเกต) ของ จำนวนข้อมูลทั้งหมด โดยในขั้นตอนถัดมาคือการนำข้อมูลที่แบ่งไว้เพื่อเทรนโมเดลไปเทรนโมเดลตามโมเดลที่ กำหนดไว้ ได้แก่ Decision Tree และ Random Forest จากนั้นเมื่อเทรนโมเดลเสร็จเรียบร้อยแล้วจะนำข้อมูล ส่วนที่เหลือหรือข้อมูลส่วนที่แบ่งไว้เพื่อทดสอบมาทำการทดสอบความแม่นยำในการพยากรณ์ของโมเดลทั้งสอง และทำการประเมินผล โดยการประเมินผลของแต่ละโมเดลจะใช้ Confusion Matrix ในการประเมินผล

โดยรายละเอียดเกี่ยวกับโค้ดที่ใช้ในการสร้างแบบจำลอง: <https://github.com/PMAHC404/Project-Credit-Rating-Machine-Learning>

ผลการศึกษา

ผลการศึกษา Spearman Rank Correlation Test ที่ทดสอบความสัมพันธ์ระหว่างตัวแปรอิสระทั้งที่เป็นอัตราส่วนทางการเงินและไม่ใช่อัตราส่วนทางการเงินกับตัวแปรตามคืออันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้ พบว่าอัตราส่วนผลตอบแทนต่อสินทรัพย์ (ROA) อัตราส่วนผลตอบแทนต่อส่วนของผู้ถือหุ้น (ROE) ความสามารถในการจ่ายดอกเบี้ย (ICR) ขนาดของกิจการ (SIZE) และอัตราส่วนกำไรก่อนดอกเบี้ยจ่ายและภาษีต่อรายได้ (EBIT_Margin) มีความสัมพันธ์กับอันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้ที่ระดับนัยสำคัญทางสถิติ $\alpha = 0.01$ อัตราส่วนหนี้สินต่อส่วนของผู้ถือหุ้น (D/E Ratio) มีระดับนัยสำคัญทางสถิติ $\alpha = 0.05$ และอัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคาและค่าตัดจำหน่ายต่อรายได้ (EBITDA_Margin) มีระดับนัยสำคัญทางสถิติ $\alpha = 0.1$ และตัวแปรที่ไม่มีความสัมพันธ์กับอันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้ ได้แก่ Net Working Capital to Total Assets (NWCTA)

ตารางที่ 4 ตารางแสดงผลการทดสอบ Spearman Rank Correlation Test

	ROA	ROE	D/E Ratio	ICR	SIZE	NWCTA	EBIT_Margin	EBITDA_Margin
r	0.4601	0.4248	-0.1385	0.466	0.7771	0.0748	0.2291	0.1174
t - stat	6.576	5.953	-1.775	6.683	15.665	0.951	2.986	1.5
p - value	0.000***	0.000***	0.039**	0.000***	0.000***	0.171	0.002***	0.068*

หมายเหตุ: * คือ มีนัยสำคัญทางสถิติที่ = 0.10

** คือ มีนัยสำคัญทางสถิติที่ = 0.05

*** คือ มีนัยสำคัญทางสถิติที่ = 0.01

ผลการพยากรณ์ของแบบจำลอง

ผลการพยากรณ์อันดับเครดิตเรตติ้งของผู้ออกตราสารหนี้ ซึ่งประกอบไปด้วยแบบจำลองที่ 1 คือแบบจำลองที่ใช้ algorithm แบบ Decision Tree และแบบจำลองที่ 2 คือแบบจำลองที่ใช้ algorithm แบบ Random Forest โดยที่ทั้งสองแบบจำลองนั้นใช้วิธีการสุ่มตัวอย่าง (Sampling method) แบบ Leave One Out Cross Validation (LOOCV) และใช้วิธีในการประเมินผลแบบจำลองด้วย Confusion Matrix ด้วยค่า Accuracy, Precision, Recall และ F1-score

โดยผลของการประเมินคุณภาพของแบบจำลองที่ 1 พบว่าตัวแปรที่มีความสำคัญต่อการพยากรณ์อันดับเครดิตเรตติ้งมากที่สุดคือ ขนาดของกิจการ (SIZE) ความสามารถในการจ่ายดอกเบี้ย (ICR) อัตราส่วนผลตอบแทนต่อสินทรัพย์ (ROA) อัตราส่วนผลตอบแทนต่อส่วนของผู้ถือหุ้น (ROE) อัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคาและค่าตัดจำหน่ายต่อรายได้ (EBITDA_Margin) อัตราส่วนหนี้สินต่อส่วนของผู้ถือหุ้น (D/E Ratio) และ

อัตราส่วนกำไรก่อนดอกเบี้ยจ่ายและภาษีต่อรายได้ (EBIT_Margin) ตามลำดับ โดยแบบจำลองมีความแม่นยำในการพยากรณ์โดยรวม (Overall Accuracy) ร้อยละ 72.73 หมายความว่าแบบจำลองสามารถพยากรณ์ได้ถูกต้องทั้งหมด 72.73 ครั้งจากการพยากรณ์ทั้งหมด 100 ครั้ง

ถัดมาคือค่า Precision ที่แสดงถึงความสามารถของแบบจำลองในการพยากรณ์กลุ่มเป้าหมายพบว่าการพยากรณ์อันดับเครดิตแบบ Speculative Grade มีความแม่นยำมากที่สุดที่ร้อยละ 100 หมายความว่าแบบจำลองสามารถพยากรณ์สามารถพยากรณ์ว่าเป็น Speculative Grade ได้ 100 ครั้งจากจำนวนครั้งที่พยากรณ์ว่าเป็น Speculative Grade และตามมด้วย Low Investment Grade, Medium Investment Grade และ High Investment Grade ตามลำดับ

ถัดมาคือค่า Recall ที่แสดงถึงความสามารถของแบบจำลองในการพยากรณ์ของเหตุการณ์ที่สนใจ อันดับเครดิตแบบ Low Investment Grade มีความแม่นยำมากที่สุดที่ร้อยละ 90.91 หมายความว่าแบบจำลองสามารถพยากรณ์ว่าเป็น Low Investment Grade ได้ถูกต้อง 90.91 จากจำนวน Low Investment Grade ที่เกิดขึ้นจริง 100 ครั้ง

และสุดท้ายคือค่า F1-score ที่แสดงถึงความสมดุลของแบบจำลองในการพยากรณ์กลุ่มเป้าหมายและเหตุการณ์ที่สนใจ การพยากรณ์อันดับเครดิตแบบ Low Investment Grade มีความสมดุลมากที่สุดที่ร้อยละ 83.33%

ตารางที่ 5 ตารางแสดงผลการประเมินแบบจำลอง Decision Tree ด้วย Confusion Matrix

Overall Accuracy : 72.73%				
	Speculative Grade	Low Investment Grade	Medium Investment Grade	High Investment Grade
Precision	100%	76.92%	66.67%	60%
Recall	50%	90.91%	66.67%	75%
F1 - Score	66.66%	83.33%	66.67%	66.66%

ผลการประเมินคุณภาพของแบบจำลองที่ 2 พบว่าตัวแปรที่มีความสำคัญต่อการพยากรณ์อันดับเครดิตเรตติ้งมากที่สุดคือ ขนาดของกิจการ (SIZE) อัตราส่วนความสามารถในการจ่ายดอกเบี้ย (ICR) อัตราส่วนกำไรก่อนดอกเบี้ยจ่าย ภาษี ค่าเสื่อมราคาและค่าตัดจำหน่ายต่อรายได้ (EBITDA_Margin) อัตราส่วนหนี้สินต่อส่วนของผู้ถือหุ้น (D/E Ratio) อัตราส่วนผลตอบแทนต่อสินทรัพย์ (ROA) อัตราส่วนผลตอบแทนต่อส่วนของผู้ถือหุ้น (ROE) และอัตราส่วนกำไรก่อนดอกเบี้ยจ่ายและภาษีต่อรายได้ (EBIT_Margin) ตามลำดับ โดยแบบจำลองมีความแม่นยำใน

การพยากรณ์ (Overall Accuracy) ร้อยละ 93.94 หมายความว่าแบบจำลองสามารถพยากรณ์ได้ถูกต้องทั้งหมด 93.94 ครั้งจากการพยากรณ์ทั้งหมด 100 ครั้ง

ถัดมาคือค่า Precision ที่แสดงถึงความสามารถของแบบจำลองในการพยากรณ์กลุ่มเป้าหมายพบว่าการพยากรณ์อันดับเครดิตแบบ Speculative Grade, Medium Investment Grade และ High Investment Grade มีความแม่นยำมากที่สุดที่ร้อยละ 100 หมายความว่าแบบจำลองสามารถพยากรณ์สามารถพยากรณ์ว่าเป็น Speculative Grade, Medium Investment Grade และ High Investment Grade ได้ 100 ครั้งจากจำนวนครั้งที่พยากรณ์ว่าเป็นเกรดนั้น ๆ 100 ครั้ง และตามมด้วย Low Investment Grade ที่มีค่า Precision ต่ำที่สุดที่ 84.62%

และค่า Recall ที่แสดงถึงความสามารถของแบบจำลองในการพยากรณ์ของเหตุการณ์ที่สนใจ อันดับเครดิตแบบ Low Investment Grade และ High Investment Grade มีความแม่นยำมากที่สุดที่ร้อยละ 100 หมายความว่าแบบจำลองสามารถพยากรณ์ว่าเป็น Low Investment Grade และ High Investment Grade ได้ถูกต้อง 100 ครั้ง จากจำนวน Low Investment Grade และ High Investment Grade ที่เกิดขึ้นจริง 100 ครั้ง และสุดท้ายคือค่า F1-score ที่แสดงถึงความสมดุลของแบบจำลองในการพยากรณ์กลุ่มเป้าหมายและเหตุการณ์ที่สนใจ การพยากรณ์อันดับเครดิตแบบ High Investment Grade มีความสมดุลมากที่สุดที่ร้อยละ 100%

ตารางที่ 6 ตารางแสดงผลการประเมินแบบจำลอง Random Forest ด้วย Confusion Matrix

Overall Accuracy : 93.94%				
	Speculative Grade	Low Investment Grade	Medium Investment Grade	High Investment Grade
Precision	100%	84.62%	100%	100%
Recall	83.33%	100%	91.67%	100%
F1 - Score	90.91%	91.67%	95.65%	100%

สรุป

จากผลการสร้างแบบจำลองการพยากรณ์เครดิตเรตติ้งของผู้ออกตราสารหนี้ด้วย Machine Learning แบบ Decision Tree และ Random Forest สามารถสรุปได้ว่า ปัจจัยที่มีความสำคัญต่อการพยากรณ์มากที่สุดในทั้งสองแบบจำลองคือ ขนาดของกิจการ (SIZE) และน้อยที่สุดคืออัตราส่วนกำไรก่อนดอกเบี้ยจ่ายและภาษีต่อรายได้ (EBIT_Margin) โดยแบบจำลองที่มีความแม่นยำในการพยากรณ์มากที่สุดคือแบบจำลองที่ใช้อัลกอริทึมแบบ Random Forest โดยมีความแม่นยำโดยรวมที่ร้อยละ 93.93 โดยประโยชน์ของแบบจำลองนี้คือเป็นข้อมูลในการช่วยตัดสินใจในการลงทุนในตราสารหนี้ นอกเหนือข้อมูลจากสถาบันจัดอันดับความน่าเชื่อถือที่อาจมีปัญหาระยะเวลาในการออก และปัญหาเรื่องความโปร่งใสในการจัดอันดับ

ข้อเสนอแนะในการศึกษาครั้งต่อไป

ในการสร้างแบบจำลองการพยากรณ์อันดับเครดิตเรตติ้งครั้งต่อไปสามารถเพิ่มจำนวนหน่วยสังเกต และความหลากหลายของหน่วยสังเกตเพิ่มขึ้นได้อีก เช่น การเก็บหน่วยสังเกตที่เป็น Speculative Grade มากขึ้นเพื่อเพิ่มความหลากหลายให้กับข้อมูลที่ใช้ในการเทรนโมเดลในการพยากรณ์ และยังสามารถเพิ่มตัวแปรอื่น ๆ ที่มีความสัมพันธ์กับอันดับเครดิตเรตติ้งอย่างมีนัยสำคัญทางสถิติได้อีกเพื่อเพิ่มความแม่นยำของแบบจำลองในการพยากรณ์

บรรณานุกรม

- กรรณิกา วิวัฒน์บุตรศิริ. 2021. การศึกษาปัจจัยที่ส่งผลต่อการจัดอันดับเครดิตหุ้นกู้ของสถาบันการเงิน (Online). <https://econ.nida.ac.th/wp-content/uploads/2021/05/4-5-6210323020-2-ฉบับสมบูรณ์.pdf>, 9 มกราคม 2024.
- ฐาณินี ดันโสรัจประเสริฐ. 2021. ปัจจัยที่ส่งผลต่อการจัดอันดับความน่าเชื่อถือของบริษัทที่จัดอยู่ในดัชนี MSCI โดยสถาบันจัดอันดับ Moody's (Online). <https://archive.cm.mahidol.ac.th/bitstream/123456789/4296/1/TP%20FM.023%202564.pdf>, 9 มกราคม 2024.
- ธนาคารแห่งประเทศไทย. 2024. อัตราดอกเบี้ยในตลาดเงิน (Online). https://app.bot.or.th/BTWS_STAT/statistics/BOTWEBSTAT.aspx?reportID=223&language=TH, 12 กุมภาพันธ์ 2024.
- ธรณัณย์ หวังคนาลาก. 2017. การศึกษาการจัดอันดับเครดิตกับอัตราส่วนทางการเงินและปัจจัยอื่น ๆ (Online). https://ethesisarchive.library.tu.ac.th/thesis/2017/TU_2017_5902112647_7810_7013.pdf, 9 มกราคม 2024.
- สำนักข่าวอิสรา. 2023. หวั่นชำระ EARTH! จับตาที่ประชุมผู้ถือหุ้น STARK ถกความเสี่ยงผิดนัดชำระหนี้ 9.1 พันล. (Online). <https://www.isranews.org/article/isranews-news/118069-STARK-Bond-default-risk-news.html>, 20 ธันวาคม 2023.
- สำนักงานคณะกรรมการกำกับหลักทรัพย์และตลาดหลักทรัพย์. 2023. มูลค่าและจำนวนผู้ลงทุน จำแนกตามประเภทผู้ถือครองตราสารหนี้ (Online). https://secopendata.sec.or.th/Investor/INV_DE, 12 กุมภาพันธ์ 2024.
- เอนก อรุณศรีแสงไชยและคณะ. 2011. ความสัมพันธ์ระหว่างอัตราส่วนทางการเงินกับอันดับเครดิตของบริษัทจดทะเบียน (Online). <https://so05.tci-thaijo.org/index.php/TER/article/view/137425/102301>, 9 มกราคม 2024.
- Big Data Institute. 2021. การวิเคราะห์ความสัมพันธ์กับข้อมูลขนาดใหญ่ (Online). <https://bdi.or.th/big-data-101/correlation-analysis-in-big-data/#:~:text=ค่า%20Spearman%20Correlation%20เป็นการหาความ,ค่า%20Spearman%20Correlation%20ใกล้%20-1.0>, 12 กุมภาพันธ์ 2024.
- Bornto Dev. 2021. มารู้จักกับ Decision Tree (Online). <https://www.facebook.com/borntodev/photos/a.830302417028053/4223115914413336/?type=3>, 12 กุมภาพันธ์ 2024.

Cyber Elite. 2022. **Machine Learning** เทคโนโลยีประโยชน์ครอบคลุมจักรวาล (Online).

<https://www.cyberelite.co.th/blog/machine-learning/>, 12 กุมภาพันธ์ 2024.

Everyday Marketing. 2023. **นักการตลาดกับ AI: Confusion Matrix และหลักการประเมิน**

ประสิทธิภาพ ML Model (Online). <https://www.everydaymarketing.co/business-and-marketing-case-study/ai/confusion-matrix-ml-evaluation/#:~:text=เราจึงสามารถสรุปได้,รูปแบบของตารางเมท,> 12 กุมภาพันธ์ 2024.

Kapook. 2023. **แอน จักรพงษ์ ผิดนัดชำระหนี้หุ้นกู้ JKN กว่า 600 ล้าน ชำระได้แค่ 156 ล้าน** (Online).

<https://highlight.kapook.com/view/235984>, 20 ธันวาคม 2023.

Phuri Chalermkiatsakul. 2018. **Supervised Learning คืออะไร? ทำงานยังไง?** (Online).

<https://phuri.medium.com/supervised-learning-คืออะไร-ทำงานยังไง-1c0e411a40a2>,
12 กุมภาพันธ์ 2024.

PPTV Online. 2023. **ALL ผิดนัดจ่ายหนี้หุ้นกู้ 2,416 ล้านบาท ตลท.เตือนนักลงทุนระมัดระวัง** (Online).

<https://www.pptvhd36.com/news/หุ้น-การลงทุน/202347>, 20 ธันวาคม 2023.

Set smart. 2024. **Financial Data & Financial Ratio** (Online). <https://www.setsmart.com/ssm/marketSummary>, 12 กุมภาพันธ์ 2024.

ThaiBMA. 2017. **อันดับความน่าเชื่อถือ (Credit Rating)** (Online). <https://www.thaibma.or.th/EN/Investors/Individual/Blog/CreditRating.aspx>, 12 กุมภาพันธ์ 2024.

Tris Rating. 2024. **Rating List** (Online). <https://www.trisrating.com/register?rcID=507>,
12 กุมภาพันธ์ 2024.

Witchapong Daroontham. 2018. **เจาะลึก Random Forest !!!— Part 2 of “รู้จัก Decision Tree, Random Forest, และ XGBoost!!!”** (Online). <https://medium.com/@witchapongdaroontham/เจาะลึก-random-forest-part-2-of-รู้จัก-decision-tree-random-forest-และ-xgboost-79b9f41a1c1c>, 12 กุมภาพันธ์ 2024.